IA LOCAL

Quer usar IA sem pagar API por cada pedido?



+

HERMES-AGENT

ESTE GUIA ENSINA

A rodar a IA no seu computador, do zero, com Ollama e Hermes Agent

O QUE É CADA UM

Dois programas, uma dupla.

Ollama

roda modelos de IA direto no seu computador. Código aberto (MIT), mais de 185 mil estrelas no GitHub.

Hermes Agent

agente da Nous Research (MIT, mais de 258 mil estrelas): executa tarefas no terminal, agenda automações e conversa por Telegram ou Discord.

Juntos

o Ollama é o motor que roda o modelo e o Hermes é o agente que usa esse modelo para trabalhar.

Privacidade

rodando local, a documentação do Ollama diz que ele não vê seus prompts nem seus dados.

ANTES DE COMEÇAR

O que o seu computador precisa ter.

Mac ou Linux

os comandos deste guia são os de instalação para Mac e Linux

Memória

o modelo recomendado pelo guia do Hermes, o gemma4:31b, pede 24 GB de RAM ou mais e cerca de 20 GB em disco

Máquina menor

com 8 GB de RAM só cabem modelos pequenos (3B), e o agente funciona melhor com modelo que chama ferramentas

Internet

só para baixar os programas e o modelo

Software gratuito não quer dizer custo zero: o que some é a cobrança de API, a máquina continua por sua conta.

PASSO 1

Instale o Ollama.

Pelo terminal

```
curl -fsSL https://ollama.com/install.sh | sh
```

Cole no Terminal e aperte Enter.

Ou pelo app

Baixe o Ollama.dmg em ollama.com/download/mac e arraste para Aplicativos.

Confira

```
ollama ls
```

O comando lista os modelos baixados. No começo a lista vem vazia.

PASSO 2

Baixe um modelo.

Modelo do guia do Hermes

```
ollama pull gemma4:31b
```

Baixa uns 20 GB, então vale deixar rodando com calma.

Testar na conversa

```
ollama run gemma4:31b
```

Abre um chat no terminal para ver se o modelo responde.

Comandos úteis

```
ollama ps  # o que está carregado
ollama stop gemma4:31b
ollama rm gemma4:31b
```

ps mostra os modelos ativos, stop descarrega e rm apaga do disco.

PASSO 3

Ligue o Hermes ao Ollama.

Caminho rápido

```
ollama launch hermes
```

Instala o Hermes Agent se faltar e já aponta para o Ollama em http://127.0.0.1:11434/v1.

Depois, use

```
hermes
```

Abre o agente no terminal.

Se preferir fazer cada etapa à mão, o caminho manual está na página seguinte.

PASSO 3, CAMINHO MANUAL

Instale e configure o Hermes.

Instalar o Hermes Agent

```
curl -fsSL https://hermes-agent.nousresearch.com/install.sh | bash
```

Configurar

```
hermes setup
```

Escolha Custom Endpoint, URL http://localhost:11434/v1, chave vazia (ou no-key) e o modelo gemma4:31b.

Abrir

```
hermes
```

PASSO 4

Aumente o contexto do Ollama.

Por quê

O Hermes exige no mínimo 64.000 tokens de contexto para usar ferramentas, e o Ollama vem com um valor bem menor.

Crie um arquivo chamado Modelfile

```
FROM gemma4:31b
PARAMETER num_ctx 64000
```

Gere o modelo novo

```
ollama create gemma4-64k -f Modelfile
```

O nome gemma4-64k é livre. Use esse modelo no hermes setup.

Mantenha carregado

```
export OLLAMA_KEEP_ALIVE=24h
```

Sem isso o modelo descarrega depois de 5 minutos parado.

PASSO 5

Use no dia a dia.

Abrir o agente

```
hermes
```

Trocar de provedor

```
hermes model
```

Dá para apontar o Hermes para um modelo na nuvem quando a tarefa pedir mais.

Conversar por mensagem

```
hermes gateway setup
```

Opcional: liga o agente ao Telegram, Discord e outros.

O QUE VALE TESTAR

Onde a dupla faz sentido para PM.

Dados sensíveis

rascunhos, documentos internos e dados de cliente sem sair do seu computador

Aprender sem medo da fatura

errar, repetir e testar prompts sem ver o gasto de API subir

Automações agendadas

o Hermes roda tarefas agendadas e avisa pelo Telegram ou Discord

Plano B local

um agente que continua útil quando a assinatura ou a cota da nuvem acaba

Ideias para testar, não promessas: teste com tarefas pequenas antes de confiar.

LIMITES HONESTOS

O que o guia oficial avisa.

Só tarefa com ferramenta

modelo sem chamada de ferramentas só conversa: não edita arquivo nem navega

Velocidade

só com CPU, o gemma4:31b responde a 2 a 5 tokens por segundo e um modelo de 9B a uns 10

Raciocínio longo

para tarefas de várias etapas e contexto grande, modelos de 70B ou mais, ou a nuvem, ainda ganham

Primeira resposta

a primeira resposta demora mais, porque o modelo precisa carregar

LINKS OFICIAIS

Tudo para começar.

Ollama
ollama.com

Hermes Agent, da Nous Research
github.com/NousResearch/hermes-agent

Guia oficial do Hermes com Ollama
hermes-agent.nousresearch.com/docs/guides/local-ollama-setup

Como o Ollama liga no Hermes
docs.ollama.com/integrations/hermes

Os comandos vêm da documentação oficial dos dois projetos, conferida em 30/10/2026.